Итоги разведочного анализа

MovieLens 32M | Рекомендательная система фильмов | Команда 129

Данные и задача

Исследованы 32 000 204 оценки от 200 948 пользователей для 84 432 оценённых объектов; полный каталог содержит 87 585 записей. Цель проекта - рекомендовать пользователю 10 фильмов по истории оценок. Исходный порог положительной оценки - 4 из 5; дополнительно проверены пороги 3,5 и 4,5.

Качество и обработка данных

Дубликатов оценок, повторных пар пользователь-фильм и значений вне шкалы нет. У 7 080 объектов отсутствует жанр (8,08%), у 124 - tmdbId (0,14%); год не извлечён у 771 записи. Удалены 6 пустых тегов; строки NA и null сохранены как текст. Неизвестный жанр заменён на Unknown, пропуски года и внешнего ID сохранены. В tmdbId есть 36 повторных значений: таблицы связываем по movieId. Валидные крайние оценки и экстремальная активность сохранены.

Основные результаты и выводы для модели

Результат EDA	Вывод для рекомендательной системы
Разреженность матрицы - 99,81%.	Использовать разреженные взаимодействия; отсутствие оценки не считать отрицательным отзывом.
1% оценённых фильмов собирает 54,88% оценок. У 48,02% фильмов меньше пяти оценок.	Сравнить персональную модель с популярностью; отдельно оценить редкие фильмы и покрытие каталога.
Связь validation-рейтинга с train-средними пользователя и фильма: Spearman 0,389 и 0,385.	Проверить средние и смещения как признаки. Рассчитывать агрегаты только по обучающему периоду.
Теги есть у 57,05% оценённых объектов. По числу оценок лидируют Drama, Comedy и Action.	Использовать жанры и доступные к моменту обучения теги как дополнительные признаки.

Временное разбиение и холодный старт

Оценки разделены по времени примерно в пропорции 80/10/10. В тесте 85,67% событий относятся к новым относительно train пользователям, 13,81% - к новым фильмам; группы пересекаются. При пороге 4 и наличии положительной истории пользователя и фильма в train для персонализации подходят 4 295 тестовых пользователей. Качество нужно оценивать отдельно для знакомых и новых пользователей и фильмов.

Ограничения и следующий этап

MovieLens содержит оценки, а не полную историю просмотров; данные заканчиваются в октябре 2023 года. Все пользователи отобраны с минимум 20 оценками, а медианная длительность выставления оценок - 94 минуты. Попарные связи рассчитаны на 200 000 validation-событий, scatter matrix - на 3 000 полных строк, seed=42. Следующий этап: сравнить популярность и персональную модель по NDCG@10, Recall@10 и покрытию каталога. Обучение моделей и измерение этих метрик ещё не выполнены.

Расчёты, графики и выводы: EDA.ipynb

Источник: GroupLens, MovieLens 32M.